

UNIVERSIDADE DE SÃO PAULO
ESCOLA DE ARTES, CIÊNCIAS E HUMANIDADES
Programa de Pós-Graduação em Modelagem de Sistemas
Complexos

Plano de Pesquisa

Hyslan Silva Cruz

Título

Dinâmica de Interação e Comportamento Emergente em Redes Complexas de Múltiplos Agentes Baseados em LLMs Locais

Introdução: Objetivos e Justificativa

A modelagem de sistemas complexos fornece o arcabouço matemático e computacional necessário para entender como interações locais entre componentes individuais geram comportamentos globais emergentes. Recentemente, a adoção de Modelos de Linguagem de Grande Escala (LLMs) impulsionou a criação de sistemas multiagentes autônomos. No entanto, o estudo da dinâmica de rede formada por múltiplos agentes que operam de maneira descentralizada (edge computing) e baseada em LLMs de código aberto executados localmente ainda é incipiente.

Objetivo Geral: Modelar e simular as interações em uma rede complexa de agentes autônomos impulsionados por LLMs quantizados (como Dolphin-Mistral e Qwen), analisando a emergência de fenômenos como consenso, polarização e difusão de informação sob restrições de hardware e conectividade local.

Objetivos Específicos:

- Desenvolver um modelo matemático baseado em grafos e álgebra linear para representar o fluxo de informações probabilísticas entre os agentes.
- Implementar um ambiente de simulação em Python e Rust para orquestrar a comunicação descentralizada entre instâncias de LLMs locais.
- Analisar o impacto da topologia da rede nas taxas de convergência de ideias ou resolução cooperativa de problemas complexos.

Justificativa: A dependência de APIs centralizadas de modelos de linguagem cria gargalos de privacidade, latência e custo. Ao investigar redes de agentes rodando inferência localmente, este projeto contribui para a literatura de sistemas complexos aplicados à inteligência artificial distribuída, unindo o rigor formal matemático às necessidades reais de infraestruturas tecnológicas modernas.

Revisão Bibliográfica

O estudo de comportamentos emergentes em sistemas sociais e computacionais tem suas raízes na física estatística e na teoria de grafos (Barabási, 2016). No contexto de agentes autônomos, modelos matemáticos tradicionais frequentemente assumem comportamentos estocásticos simplificados. Contudo, trabalhos recentes de Park et al. (2023) demonstraram que a integração de LLMs como motor cognitivo de agentes produz interações sociais de alta complexidade.

Diferentemente dos modelos centralizados, a inferência na borda (*edge computing*) introduz restrições assíncronas e heterogeneidade cognitiva (modelos menores de 7B e 14B parâmetros). A transição de fase nestes sistemas — por exemplo, a rapidez com que a rede inteira chega à solução de um problema — requer modelagens com equações diferenciais e grafos dinâmicos para entender como o "conhecimento" se propaga e se estabiliza sem um coordenador central.

Metodologia e Plano de Atividades

A metodologia divide-se em três etapas inter-relacionadas:

1. Modelagem Matemática e Topológica: Formulação do ambiente através de matrizes de adjacência e cálculos de limites de grafos, representando as conexões entre agentes. A dinâmica de estado será avaliada usando métodos de cálculo numérico.

2. Implementação Computacional: O ambiente será estruturado em um servidor bare-metal baseado em Debian. Utilizaremos *LM Studio* e *AnythingLLM* para hospedar localmente diferentes instâncias quantizadas (Qwen, Dolphin-Mistral). O orquestrador da simulação será desenvolvido em Python (para integração rápida de IA) e componentes críticos de rede em Rust (para paralelismo eficiente).

3. Simulação e Coleta de Dados: Serão rodados cenários com diferentes topologias (redes *scale-free*, *small-world*) observando as métricas de tempo para consenso e divergência comportamental.

Plano de Atividades (24 meses):

- **Meses 1-6:** Conclusão dos créditos em disciplinas, revisão sistemática da literatura e definição rígida das equações diferenciais do modelo.

- **Meses 7-12:** Desenvolvimento da arquitetura de simulação em Python/Rust e integração com os LLMs rodando no servidor Debian.
- **Meses 13-18:** Execução dos experimentos computacionais e análise estatística dos dados emergentes da rede.
- **Meses 19-24:** Redação da dissertação, submissão de artigos e defesa.

Resultados Parciais

A pesquisa já se encontra em fase de fundamentação e testes preliminares de infraestrutura. Atualmente, o referencial teórico está sendo construído concomitantemente ao curso das disciplinas SCX5000 e SCX5002 do programa de pós-graduação, cursadas na modalidade de aluno especial, fornecendo o rigor conceitual exigido. Em paralelo, a infraestrutura local em servidor Debian já foi configurada com sucesso para testes iniciais de *workloads* de IA e automação, atestando a viabilidade técnica de rodar modelos como Dolphin-Mistral e Qwen para a fase empírica do projeto.

Referências Bibliográficas

- BARABÁSI, A.-L. *Network Science*. Cambridge: Cambridge University Press, 2016.
- NEWMAN, M. E. J. *Networks: An Introduction*. Oxford University Press, 2010.
- PARK, J. S. et al. Generative Agents: Interactive Simulacra of Human Behavior. *arXiv preprint*, arXiv:2304.03442, 2023.
- WANG, L. et al. Survey on Large Language Model based Autonomous Agents. *Frontiers of Computer Science*, 2024.