

Hyslan Silva Cruz

Modelagem de Redes Complexas de Agentes Autônomos com LLMs Quantizados em Edge Computing

Suzano

2026

Hyslan Silva Cruz

Modelagem de Redes Complexas de Agentes Autônomos com LLMs Quantizados em Edge Computing

Plano de Pesquisa apresentado ao Programa de Pós-Graduação em Modelagem de Sistemas Complexos da Escola de Artes, Ciências e Humanidades da Universidade de São Paulo como requisito parcial para obtenção do título de Mestre em Modelagem de Sistemas Complexos.

Universidade de São Paulo

Suzano

2026

Sumário

1	INTRODUÇÃO	3
1.1	Justificativa	3
1.1.1	Objetivo Geral	3
1.1.2	Objetivos Específicos	3
2	REVISÃO BIBLIOGRÁFICA	4
3	METODOLOGIA	5
	REFERÊNCIAS	6

1 Introdução

A modelagem de sistemas complexos fornece o arcabouço matemático e computacional necessário para entender como interações locais entre componentes individuais geram comportamentos globais emergentes. Recentemente, a adoção de Modelos de Linguagem de Grande Escala (LLMs) impulsionou a criação de sistemas multiagentes autônomos. No entanto, o estudo da dinâmica de rede formada por múltiplos agentes que operam de maneira descentralizada (edge computing) e baseada em LLMs de código aberto executados localmente ainda é incipiente.

1.1 Justificativa

A dependência de APIs centralizadas de modelos de linguagem cria gargalos de privacidade, latência e custo. Ao investigar redes de agentes rodando inferência localmente, este projeto contribui para a literatura de sistemas complexos aplicados à inteligência artificial distribuída, unindo o rigor formal matemático às necessidades reais de infraestruturas tecnológicas modernas.

1.1.1 Objetivo Geral

Modelar e simular as interações em uma rede complexa de agentes autônomos impulsionados por LLMs quantizados (como Dolphin-Mistral e Qwen), analisando a emergência de fenômenos como consenso, polarização e difusão de informação sob restrições de hardware e conectividade local.

1.1.2 Objetivos Específicos

- Desenvolver um modelo matemático baseado em grafos e álgebra linear para representar o fluxo de informações probabilísticas entre os agentes.
- Implementar um ambiente de simulação em Python e Rust para orquestrar a comunicação descentralizada entre instâncias de LLMs locais.
- Analisar o impacto da topologia da rede nas taxas de convergência de ideias ou resolução cooperativa de problemas complexos.

2 Revisão Bibliográfica

O estudo de comportamentos emergentes em sistemas sociais e computacionais tem suas raízes na física estatística e na teoria de grafos (Barabási, 2016). No contexto de agentes autônomos, modelos matemáticos tradicionais frequentemente assumem comportamentos estocásticos simplificados. Contudo, trabalhos recentes de Park et al. (2023) demonstraram que a integração de LLMs como motor cognitivo de agentes produz interações sociais de alta complexidade.

Diferentemente dos modelos centralizados, a inferência na borda (*edge computing*) introduz restrições assíncronas e heterogeneidade cognitiva (modelos menores de 7B e 14B parâmetros). A transição de fase nestes sistemas — por exemplo, a rapidez com que a rede inteira chega à solução de um problema — requer modelagens com equações diferenciais e grafos dinâmicos para entender como o "conhecimento" se propaga e se estabiliza sem um coordenador central.

3 Metodologia

A metodologia divide-se em três etapas inter-relacionadas:

1. Modelagem Matemática e Topológica: Formulação do ambiente através de matrizes de adjacência e cálculos de limites de grafos, representando as conexões entre agentes. A dinâmica de estado será avaliada usando métodos de cálculo numérico.

2. Implementação Computacional: O ambiente será estruturado em um servidor bare-metal baseado em Debian. Utilizaremos *LM Studio* e *AnythingLLM* para hospedar localmente diferentes instâncias quantizadas (Qwen, Dolphin-Mistral). O orquestrador da simulação será desenvolvido em Python (para integração rápida de IA) e componentes críticos de rede em Rust (para paralelismo eficiente).

3. Simulação e Coleta de Dados: Serão rodados cenários com diferentes topologias (redes *scale-free*, *small-world*) observando as métricas de tempo para consenso e divergência comportamental.

Plano de Atividades (24 meses):

- **Meses 1-6:** Conclusão dos créditos em disciplinas, revisão sistemática da literatura e definição rígida das equações diferenciais do modelo.
- **Meses 7-12:** Desenvolvimento da arquitetura de simulação em Python/Rust e integração com os LLMs rodando no servidor Debian.
- **Meses 13-18:** Execução dos experimentos computacionais e análise estatística dos dados emergentes da rede.
- **Meses 19-24:** Redação da dissertação, submissão de artigos e defesa.

Referências